Université Paris Cité



APPRENTISSAGE MACHINE POUR LA SCIENCE DES DONNEES



Prédiction des données MNIST avec uniquement 100 labels

Réalisé par :

KPATOUKPA Kpodjro
NDIAYE Bassirou Serigne
NDIFO NGASSEU Priscille Lyse
WELEHELA TAWEUTEU Orchelle Patricia

Encadré par :

Pr Blaise HANCZAR

Table des matières

Introduction 3
1 Compréhension et résumé de l'article de base 3
2 Description des méthodes utilisées 4
2.1 Préparation des données 4
2.2 Architecture des modèles 5
2.3 Description des modèles entrainés 6
3 Résultats obtenus 8
3.1 Performances des modèles 8
3.2 Comparaison des entropies marginales 9
3.3 Comparaison des performances (métriques) 9
3.4 Comparaison des performances par classe (matrice de confusion 10
4 Limites et perspectives 11
4.1 Les limites 11
4.2 Perspectives 11
Conclusion générale 12
Références 13

Introduction

Ce projet de recherche vise à évaluer l'efficacité de l'apprentissage semi-supervisé dans un contexte où la disposition de données labelisées est très faible. Nous explorons l'impact de l'intégration de mécanismes de maximisation de l'information et de régularisation adversariale sur la qualité des représentations apprises et les performances de classification. Notre étude tire principalement sa base de l'article « UNSUPERVISED AND SEMI-SUPERVISED LEARNING WITH CATEGORICAL GENERATIVE ADVERSARIAL NETWORKS », publié par le chercheur Jost Tobias Springenberg. Notre recherche se concentre sur les modèles **Categorical Generative Adversarial Networks** (CatGAN) et **Regularized Information Maximization** (RIM), comparés à des baselines purement supervisées dans la tâche de reconnaissance des chiffres manuscrits (MNIST).

L'évaluation comparative va mettre en lumière les rôles respectifs de l'architecture (MLP vs. CNN), de l'exploitation des données non labellisées et de l'apprentissage adversarial pour améliorer les performances de classification dans des scénarios où l'annotation est coûteuse ou simplement rare.

Pour une analyse comparative, nous définirons **cinq différents modèles** qui seront évalués à l'aide de métriques standards telles que l'Accuracy, le Recall, le F1-score, l'AUC (Area Under the Curve), ainsi que des matrices de confusion.

1 Compréhension et résumé de l'article de base

- Objectif de l'article

L'article présente CatGAN (pour Categorical GAN), une extension du cadre des GANs, pensée pour entraîner un classifieur multi-classes. Ce qui est nouveau, c'est que CatGAN fonctionne en contexte non supervisé ou semi-supervisé, sans devoir modéliser explicitement la distribution des données. L'idée de base est d'associer deux approches : d'un côté, on maximise l'information mutuelle entre les données et les classes (c'est le côté discriminatif), et de l'autre, on ajoute une forme adversarial pour éviter que le modèle surapprenne, par exemple quand un classifieur finit par regrouper toutes les données dans une seule classe, une situation classique du clustering discriminatif.

- Problématique traitée

En non supervisé, on veut apprendre à classifier p(y|x) alors qu'on n'a aucune étiquette. Les méthodes traditionnelles tombent globalement dans deux camps : d'un côté, les approches génératives comme K-means ou les GMM qui cherchent à capturer la distribution p(x) ; de l'autre, les méthodes discriminatives, type RIM ou MMC, qui se concentrent sur les frontières de décision. Ces dernières sont efficaces mais elles surapprennent facilement. CatGAN cherche justement à garder la force des modèles discriminatifs, tout en les rendant plus robustes grâce à l'entraînement adversarial.

- Principes fondamentaux de CatGAN

Contrairement aux GANs classiques, où le discriminateur doit juste décider si c'est du vrai ou du faux, CatGAN utilise un classifieur avec K classes.

Pour le Discriminateur, le but est de maximiser l'info mutuelle entre les données x et les étiquettes prédites y, tout en apprenant à se méfier, voire à se mélanger les pinceaux, face aux faux exemples. En pratique, il cherche à :

- Réduire l’entropie conditionnelle sur les vraies données (donc être confiant) ;

- Augmenter l’entropie conditionnelle sur les fausses (donc rester incertain devant le faux) ;

- Maximiser l’entropie marginale des classes (pour que toutes les classes soient utilisées).

Pour le Générateur, l’objectif, c’est de piéger le discriminateur : il produit des exemples qui réduisent l’entropie conditionnelle, pour forcer le discriminateur à classer ses créations avec assurance, comme s’il s’agissait de vraies données.

- Extension à l'apprentissage semi-supervisé

Lorsqu’ on a quelques données étiquetées sous la main, CatGAN s’adapte sans problème : on ajoute simplement une fonction de perte de cross-entropie supervisée pour ces exemples-là, tout en continuant à appliquer l’objectif non supervisé sur la grosse majorité des données non étiquetées. Les étiquettes servent alors de points d’ancrage pour bien positionner les classes, et l’apprentissage adversarial permet au modèle de deviner la structure globale avec les données non labellisées.

- Conclusion

CatGAN apporte beaucoup de choses : une formulation ingénieuse qui rapproche clustering et classification, une robustesse bien supérieure aux méthodes classiques, et surtout, une vraie capacité de généralisation en mode semi-supervisé, un avant-goût des architectures multi-classes modernes qu’on voit aujourd’hui avec les GANs.

2 Description des méthodes utilisées

L’ensemble de notre étude a exploré diverses méthodes et elles reposent sur des modèles basés sur deux architectures de réseaux neuronaux.

2.1 Préparation des données

L’une des premières choses a été d’effectuer les actions nécessaires pour rendre les données exploitables aux divers modèles.

Nous avons ainsi :

- Défini une transformation pour préparer les images MNIST.
- Chargé le jeu de données MNIST d'entraînement.
- Divisé le jeu de données MNIST en deux sous-ensembles : un petit ensemble de données labellisées (étiquetées, échantillonnage stratifié) : 10 lignes pour chacun des 10 chiffres.

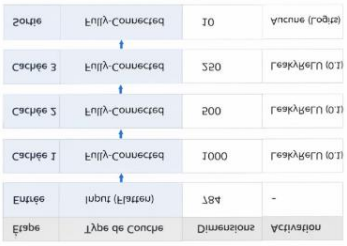
  Et un grand ensemble de données non labellisées (non étiquetées).

- Créé deux DataLoaders pour gérer le chargement efficace de ces deux ensembles pendant l'entraînement.

Le but est de simuler un scénario où l'on dispose de très peu de données étiquetées (ici, 100 images) mais d'une grande quantité de données non étiquetées, ce qui est le cadre idéal pour entraîner un GAN semi-supervisé ou un autre modèle de ce type.

2.2 Architecture des modèles

Le discriminateur est un réseau de neurones entièrement connecté (MLP) conçu pour traiter des images MNIST aplaties en vecteurs de dimension 784. Il produit en sortie des logits de classe utilisés dans les objectifs informationnels de CatGAN.



Le générateur CatGAN utilise une architecture MLP transformant un vecteur latent en une image MNIST par le biais de deux couches cachées de 500 neurones régies par des activations LeakyReLU. Le réseau projette ces caractéristiques vers une couche de sortie de 784 neurones afin de reconstruire la structure d'une image manuscrite aplatie. La fonction d'activation Sigmoid assure que les valeurs sont dans [0, 1] pour représenter fidèlement l'intensité des pixels.

Étape	Type de Couche	Dimensions	Activation
Entrée	Fully-Connected	Z_DIM	-
Cachée 1	Fully-Connected	500	LeakyReLU (0.1)
Cachée 2	Fully-Connected	500	LeakyReLU (0.1)
Sortie	Fully-Connected	784	Sigmoïde

Le discriminateur basé sur l'architecture CNN traite les images MNIST via un extracteur composé de quatre couches convolutionnelles et de deux opérations de Max-Pooling qui réduisent la résolution spatiale jusqu'à un format de 7x7 pixels. Les caractéristiques extraites sont ensuite aplaties et projetées à travers une couche dense de 128 neurones activée par un LeakyReLU pour condenser l'information et raffiner les motifs discriminants. Le réseau se termine par une couche linéaire projetant ces représentations vers dix logits, permettant une classification multi-classes robuste au sein du cadre antagoniste du CatGAN.

Étape	Type de Couche	Dimensions & Paramètres	Activation
Entrée	Conv2D	32 filters, 5×5 Padding 2	LeakyReLU (0.1) MaxPool2D (x2)
Conv2D 2	Conv2D 2	64 filters, 3×3 Padding 1	LeakyReLU (0.1)
Conv2D 3	Conv2D 3	64 filters, 3×3 Padding 1	LeakyReLU (0.1) MaxPool2D (x2)
Flatten	Flatten	128×7×7	Sigmoïde
Fully Connected	Fully-Connected	128	LeakyReLU (0.1)
Fully	Fully-Connected	10	Aucune (Logits)

Le générateur basé sur l'architecture CNN projette d'abord le vecteur latent vers une carte de caractéristiques de 7x7 pixels avant de doubler progressivement cette résolution par deux étapes successives d'upsampling et de convolutions à 64 et 32 filtres. La fonction d'activations LeakyReLU entre les couches facilite l'apprentissage de structures spatiales complexes à partir du bruit initial pour atteindre le format de sortie de 28x28. Une convolution terminale associée à une fonction Sigmoid finalise l'image MNIST en un seul canal, garantissant ainsi des intensités de pixels rigoureusement normalisées entre 0 et 1.

Étape	Type de Couche	Dimensions & Paramètres	Activation
Entrée	Fully-Connected	128×7×7	LeakyReLU (0.1) MaxPool2D (x2)
Upsample	Upsample	7×7→14	-
Conv2D 1	Conv2D 1	64 filters, 5×5 Padding 2	LeakyReLU (0.1) MaxPool2D (x2)
Conv2D 2	Conv2D 2	64 filters, 3×3 Padding 1	LeakyReLU (0.1) MaxPool2D (x2)
Flatten	Fully-Connected	128×7×7	Sigmoïde

2.3 Description des modèles entrainés

Dans cette rubrique, nous allons décrire les cinq modèles que nous avons entrainées. Parmi ces modèles, deux servent de Baselines, deux sont des modèles CatGAN, et le dernier est modèle de structure RIM.

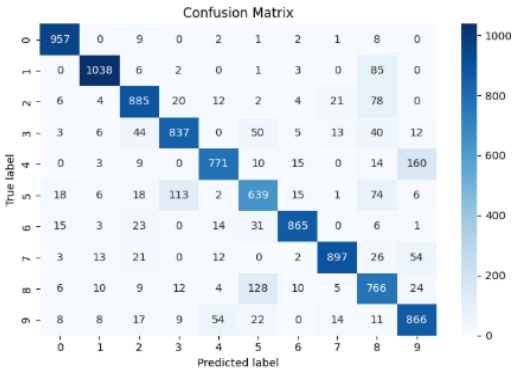
- Baseline (1)
  La première baseline repose uniquement sur le modèle discriminateur (MLP).
  Nous l'avons entrainé sur les 100 labels. En faisant varier le nombre d'itérations, les meilleures performances ont été obtenues avec le nombre d'épochs égal à 100.

- Baseline (2)
  La seconde baseline a été réalisée pour évaluer l'introduction des couches de convolution ainsi du discriminateur. Le modèle de baseline est entrainé sur les 100 données labelisées sur 100 épochs. Bien qu'une minime augmentation de la précision soit observée, on a noté la difficulté du modèle à se stabiliser en raison d'insuffisance des données. Cela a été remarqué via la courbe ROC et la courbe des pertes.

- CatGan (architecture MLP)
  L'entraînement du modèle repose sur un schéma semi-supervisé adversarial inspiré de CatGAN, combinant un grand volume de données non labellisées avec un ensemble très restreint de 100 exemples labellisés. Initialement, l'apprentissage a été lancé sur 50 époques afin d'analyser la dynamique des pertes et la stabilité du jeu adversarial.
  À chaque itération, nous alternons l'optimisation du discriminateur et du générateur.
  Le discriminateur reçoit des images réelles non labellisées, des images synthétiques produites par le générateur ainsi qu'un petit batch d'images labellisées recyclé de manière cyclique.
  Son objectif est de :
  - Produire des prédictions confiantes sur les données réelles (minimisation de l'entropie conditionnelle),
  - Utiliser l'ensemble des classes de manière équilibrée sur le jeu non labellisé (maximisation de l'entropie marginale),
  - Être incertain sur les données générées, tout en respectant les labels disponibles via une perte supervisée pondérée.

  Le générateur n'a pas pour vocation de produire des images réalistes, mais de régulariser l'apprentissage du discriminateur. Il est entraîné pour générer des échantillons qui perturbent la structure informationnelle du discriminateur, en l'obligeant à répartir ses prédictions sur l'ensemble des classes.
  Les pertes du discriminateur, du générateur, la perte supervisée et l'entropie marginale sont suivies à chaque époque afin de surveiller la convergence et la stabilité de l'apprentissage.
  L'analyse des courbes montre une convergence rapide, les pertes se stabilisant entre la 10e et la 20e époque. En conséquence, l'entraînement est finalement restreint à **15 époches**, ce qui permet d'obtenir de très bonnes performances tout en limitant le risque de sur-apprentissage et l'instabilité adversariale.

La matrice de confusion montre une très bonne performance globale, avec une diagonale fortement marquée indiquant que la majorité des chiffres sont correctement classés. Les classes 0 et 1 sont particulièrement bien reconnues, avec très peu d'erreurs. Les principales confusions concernent des chiffres morphologiquement proches, notamment 4 ↔ 9, 8 ↔ 5 et 5 ↔ 3.



Ces erreurs sont cohérentes avec la structure visuelle similaire de ces chiffres en écriture manuscrite. Les classes 4, 5 et 8 apparaissent ainsi comme les plus difficiles à distinguer pour le modèle.

- CatGAN (architecture CNN)

La méthodologie de l'entrainement de la version CNN du modèle CatGAN est restée identique à celle de MLP. Les données sont réorganisées pour ne plus être aplaties avant d'entrer dans la première couche du modèle.

L'analyse des courbes de perte a indiqué que le modèle est encore en phase d'apprentissage après **50 époches**. Les gradients restent décroissants et n'ont pas encore atteint un point de convergence stable, ce qui suggère que l'optimisation peut être poursuivie sans risque immédiat de sur-apprentissage.

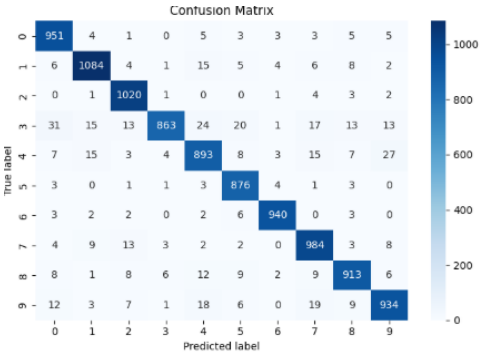
En prolongeant l'entraînement jusqu'à **75 époches**, on observe une stabilisation claire des courbes, traduisant une convergence effective du modèle. Les variations des pertes deviennent marginales, indiquant que le modèle a atteint un régime stationnaire.

À l'exception d'une légère différence d'échelle entre les représentations en log10 et celles basées sur l'entropie, les deux métriques présentent une dynamique très similaire, confirmant la cohérence de l'apprentissage et la stabilité du comportement du modèle.

A vu d'œil, la première chose frappante est la netteté de la diagonale. Le modèle ne se contente plus de bien classer, il le fait de manière homogène sur toutes les classes :

_ Scores records : Les chiffres 1 (1084), 2 (1020) et 7 (984) sont identifiés avec une précision quasi parfaite.

_Redressement du "5" : Alors que dans la matrice précédente, le 5 était le maillon faible (535 succès), il remonte ici à 876.



C'est une progression majeure.

Le modèle a réussi à éliminer les erreurs systématiques qui handicapaient les versions précédentes :

- Le duel 4 vs 9 : Il n'y a plus que 27 erreurs de confusion du 4 vers le 9, contre 160 auparavant.
- Le duel 5 vs 8 : La confusion massive a disparu. Le modèle distingue désormais très bien ces deux formes.
- Le duel 3 vs 5 : Réduit à seulement 20 erreurs.

- RIM

Le modèle RIM est entraîné directement sur 75 époques, sans phase préalable de pré-entraînement, afin de permettre à l'optimisation informationnelle d'atteindre une

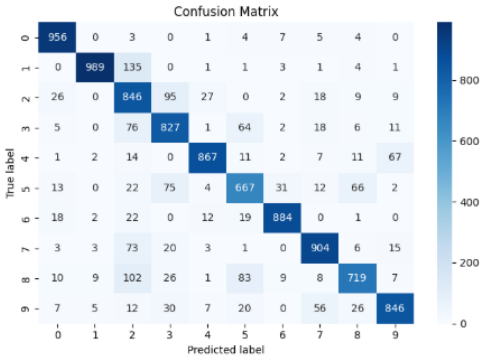
convergence stable. L'apprentissage repose sur un discriminateur convolutionnel (CNN), entraîné dans un cadre semi-supervisé avec seulement 100 exemples labellisés, utilisés de manière cyclique.

À chaque itération, le modèle est optimisé selon l'objectif RIM, qui combine :

- la maximisation de l'entropie marginale des prédictions sur les données non labellisées, afin d'encourager une utilisation équilibrée des classes,
- la minimisation de l'entropie conditionnelle sur ces mêmes données, pour favoriser des prédictions confiantes, une perte supervisée (cross-entropy) appliquée sur le petit ensemble de données labellisées, servant d'ancrage pour la structure des classes.

Les métriques suivies au cours de l'entraînement sont la perte RIM moyenne par époque et l'entropie marginale, permettant de surveiller la progression de la maximisation de l'information. Les courbes associées montrent une convergence progressive vers un régime stable, bien que plus lente et légèrement plus fluctuante que dans le cas de CatGAN, en raison de **l'absence de régularisation adversariale**.

La matrice de confusion confirme des performances globalement solides, avec une diagonale bien marquée pour la majorité des classes. Les chiffres 0, 1, 6 et 7 sont particulièrement bien reconnus, indiquant que le modèle apprend correctement certaines structures discriminantes.



Cependant, plusieurs confusions notables persistent. Les chiffres 2, 3, 5 et 8 sont les plus problématiques, avec des erreurs fréquentes entre 2 ↔ 3, 5 ↔ 3 et 8 ↔ 5, reflétant des similitudes morphologiques classiques dans MNIST.

3 Résultats obtenus

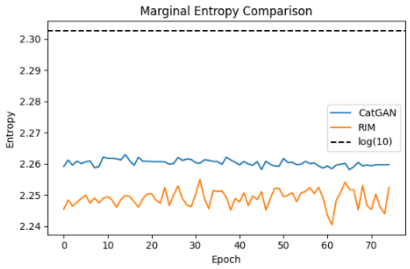
3.1 Performances des modèles

Modèle	**F1 Macro**	**Recall Macro**	**AUC Macro**	**Observations**
Baseline MLP	0.795	0.796	0.972	Baseline supervisée avec 100 labels, performance raisonnable mais n'exploite pas les données non labellisées.
CatGAN MLP	0.851	0.850	0.971	Amélioration nette (+5 points en F1/Recall) par rapport à la baseline MLP grâce à l'apprentissage semi-supervisé et la régularisation adversariale.

Modèle	F1 Macro	Recall Macro	AUC Macro	Observations
Baseline CNN	0.797	0.798	0.968	Performances comparables à la baseline MLP ; l'architecture CNN seule n'apporte pas de gain significatif sans mécanisme semi-supervisé.
RIM	0.851	0.849	0.926	Performances similaires à CatGAN-MLP, montrant l'efficacité de la maximisation de l'information seule, mais l'AUC est plus faible, indiquant une séparation de classes moins nette.
CatGAN + CNN	**0.946**	**0.946**	**0.995**	Modèle le plus performant. L'association du CNN et de CatGAN conduit à une amélioration majeure, tirant pleinement parti des représentations convolutionnelles et de la régularisation adversariale.

3.2 Comparaison des entropies marginales

Le graphique ci-contre compare l'évolution de l'entropie marginale au fil des époques pour deux modèles (CatGAN-CNN et RIM) par rapport à une valeur de référence théorique. La ligne pointillée noire représente la valeur maximale théorique de l'entropie pour un problème à 10 classes.



- CatGAN (Ligne bleue) : Le CatGAN maintient une entropie marginale très haute (autour de 2.26) et presque stable. Cela montre que le modèle CatGAN est très robuste pour maintenir une distribution uniforme des classes tout au long de l'entraînement.
- RIM (Ligne orange) : Son entropie est globalement plus faible (entre 2.24 et 2.25) et beaucoup plus instable. Les oscillations assez prononcées suggèrent que le modèle RIM hésite davantage et que sa répartition des classes varie plus d'une époque à l'autre.

Le fait que CatGAN soit plus proche de la limite théorique que RIM suggère qu'il gère mieux la séparation des clusters de données, ce qui corrèle avec le score F1 plus élevé (0.946) vu précédemment. Ce graphique confirme que CatGAN est plus efficace que RIM pour explorer l'espace des données sans négliger de classes, ce qui en fait un meilleur candidat pour l'apprentissage semi-supervisé sur ce dataset.

3.3 Comparaison des performances (métriques)

En analysant le graphique, nous avons constaté que les baselines (MLP et CNN) ont atteint des performances similaires, montrant que l'architecture seule apporte peu de gain avec seulement 100 labels.

En outre, CatGAN-MLP et RIM améliorent nettement les scores (+5 points de F1), confirmant l'intérêt de la maximisation de l'information en mode semi-supervisé.

Malgré cette amélioration, le RIM reste toutefois limité par l'absence de régularisation adversariale, comme le suggèrent son AUC plus faible et les confusions observées.

L’introduction de l’architecture CNN dans le modèle CatGAN a conduit le modèle à largement surpasser tous les autres, démontrant que la combinaison de représentations convolutionnelles et de régularisation adversariale informationnelle est la plus efficace lorsque les labels sont rares. Le CNN-CatGAN est le modèle le plus performant, montrant que l’apprentissage semi-supervisé basé sur l’information bénéficie fortement à la fois d’une architecture adaptée et d’une régularisation adversariale.

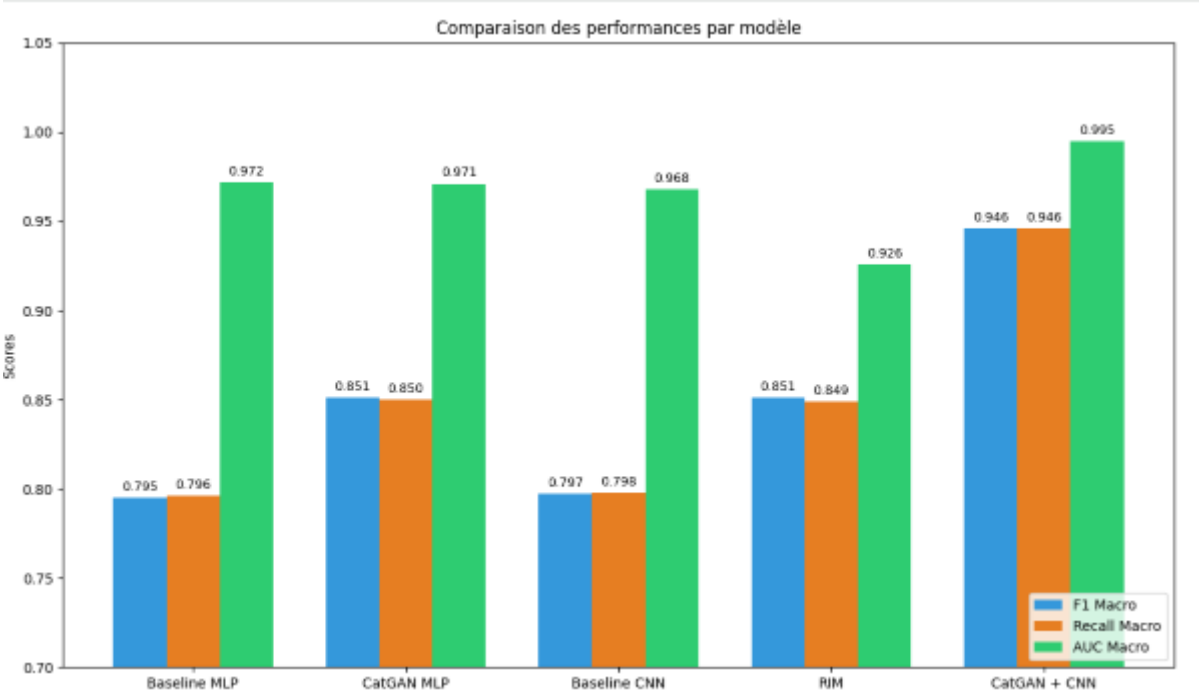


Fig 1 : Comparaison des performances des modèles

3.4 Comparaison des performances par classe (matrice de confusion

L'analyse par classe a montré que CNN-CatGAN surpasse systématiquement CatGAN-MLP et RIM sur tous les chiffres, avec des améliorations particulièrement importantes sur les classes visuellement ambiguës, soulignant l'avantage de combiner des représentations convolutionnelles avec une régularisation d'informations adverses.

- CatGAN-CNN domine systématiquement toutes les classes, en particulier les classes difficiles (2, 5, 8).
- CatGAN-MLP et RIM ont des performances proches, mais le modèle RIM chute davantage sur 5 et 8 alors que le modèle CatGAN-MLP est resté plus stable bien qu’il plafonne plus bas.
- Le gain du CNN + CatGAN est homogène sur toutes les classes, pas seulement sur les plus simples.

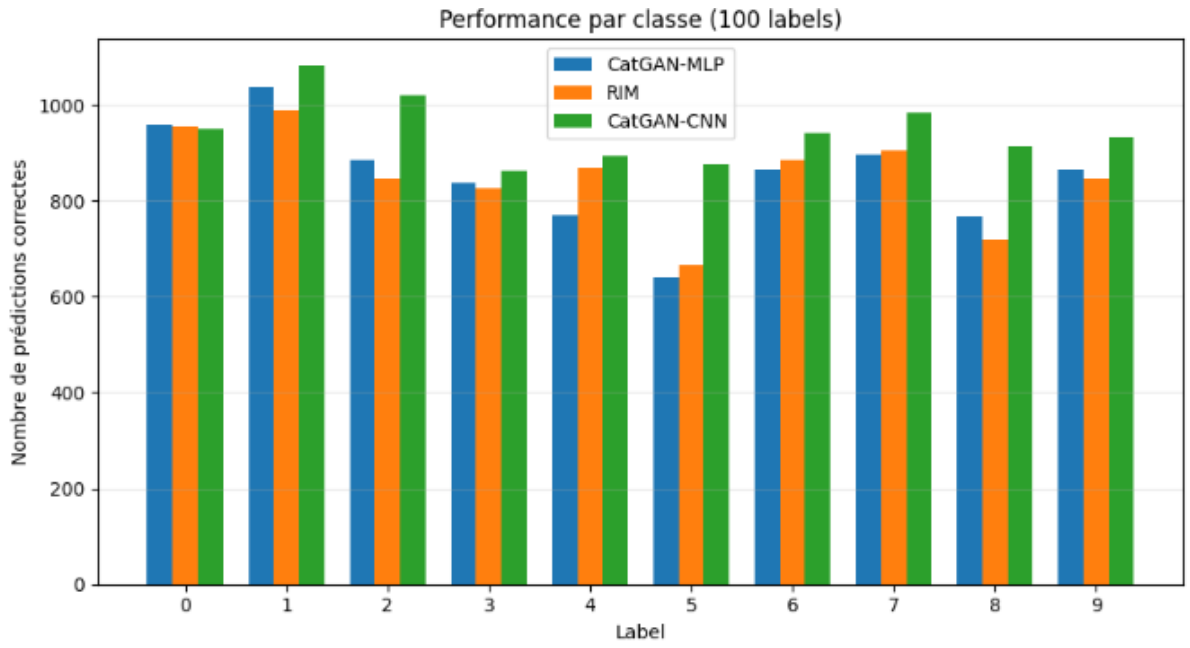


Fig 2 : Nombre de bonnes classifications par modèle par classe

4 Limites et perspectives

4.1 Les limites

Même si nous avons obtenu de très bons résultats, surtout avec CNN-CatGAN, il y a certaines limites à garder en tête. D'abord, tous les tests se sont faits sur MNIST, un jeu de données simple et bien structuré. Forcément, ça marche bien ici, mais rien ne nous dit que ce sera pareil sur des datasets plus compliqués ou avec plus de variabilité entre les classes.

En plus, même si CatGAN utilise bien les données non labellisées, son entraînement reste fragile. Il faut vraiment trouver le bon équilibre entre le générateur et le discriminateur. Ce système adversarial réagit beaucoup aux hyperparamètres comme le taux d'apprentissage, le poids du terme supervisé ou la taille du bruit latent. Du coup, il faut souvent ajuster tout ça à la main, ce qui prend du temps.

Pour RIM, c'est un peu différent. Il n'y a pas de régularisation adversariale, et cela complique l'optimisation. On se retrouve avec une séparation des classes moins nette et des performances plus faibles que CatGAN, même si l'objectif informationnel reste le même.

Et puis, il y a le cadre expérimental : on a utilisé un nombre très limité de labels (100 seulement). On n'a pas vraiment creusé l'effet d'ajouter plus de labels, donc il reste des zones d'ombre de ce côté-là.

4.2 Perspectives

Pour la suite, plusieurs pistes restent à explorer. Déjà, ce serait intéressant de tester ces méthodes sur des jeux de données plus complexes, comme Fashion-MNIST ou CIFAR-10. Ceci permettrait de voir si CatGAN et RIM tiennent la route dans des contextes plus réalistes.

On pourrait aussi essayer des architectures plus profondes ou plus récentes pour le discriminateur, comme ResNet ou Wide CNN. Avec cela, on espère apprendre des représentations encore meilleures en semi-supervisé.

Côté méthodologie, intégrer des techniques de régularisation supplémentaires, comme l'augmentation de données ou la consistency regularization, pourrait vraiment aider à stabiliser l'entraînement, surtout pour RIM. Et puis, varier la proportion de données labellisées permettrait de mieux comprendre la transition entre l'apprentissage faiblement supervisé et l'apprentissage complet.

Enfin, il serait logique de comparer CatGAN à des méthodes semi-supervisées plus récentes, surtout celles qui utilisent la cohérence ou l'auto-supervision. Ce serait un bon moyen de voir vraiment où se situe CatGAN par rapport à l'état de l'art actuel.

Conclusion générale

Dans ce projet, nous nous sommes attaqués à l'apprentissage semi-supervisé en conditions de faible supervision, en misant sur la maximisation de l'information et la régularisation adversariale, appliquées au jeu de données MNIST avec à peine 100 exemples labellisés. Nous avons testé plusieurs modèles, de simple baseline supervisé jusqu'aux approches plus costaudes basées sur l'information et l'adversarial.

Les résultats sont clairs : les modèles supervisés, qu'on utilise un MLP ou un CNN, plafonnent vite dès qu'on manque de données labellisées. Ils arrivent bien à dessiner des frontières de décision à peu près correctes, mais comme ils laissent de côté toute l'information des données non labellisées, cela bloque leur performance.

Quand on ajoute la maximisation de l'information avec RIM, on voit tout de suite une grosse différence. Exploiter les données non labellisées aide donc vraiment à structurer l'espace de représentation. Toutefois, sans régularisation adversariale, l'optimisation devient plus fragile et la séparation des classes reste perfectible.

Le meilleur score, nous l'avons obtenu avec CatGAN, surtout en combinant CNN et CatGAN. Cette combinaison a su tirer parti des représentations convolutionnelles riches et de la régularisation adversariale basée sur l'information. Résultat : des performances solides, stables sur toutes les classes, et beaucoup moins de confusions entre chiffres qui se ressemblent.

Au final, cette étude montre qu'en situation réelle, quand on a peu d'annotations, profiter à la fois des données non labellisées, de la maximisation de l'information et de la régularisation adversariale, c'est vraiment efficace. CatGAN s'impose ici comme une méthode robuste et performante pour l'apprentissage semi-supervisé, et ça ouvre la porte à plein d'extensions, vers des jeux de données plus complexes ou des architectures plus ambitieuses.

Références

[1]

Springenberg, J. T. (2016).

Unsupervised and Semi-supervised Learning with Categorical Generative Adversarial Networks (CatGAN). International Conference on Learning Representations (ICLR).

Référence principale du projet : formulation de CatGAN, maximisation de l'entropie marginale et minimisation de l'entropie conditionnelle.

[2]

Gomes, R., Krause, A., & Perona, P. (2010).

Discriminative Clustering by Regularized Information Maximization.

Advances in Neural Information Processing Systems (NeurIPS).

Fondement théorique de RIM : apprentissage non supervisé et semi-supervisé par maximisation de l'information mutuelle.

[3]

CatGAN PyTorch implementation (GitHub) : https://github.com/minlee077/CatGAN-pytorch

Fournit une implémentation en PyTorch de CatGAN, utile pour compréhension et réutilisation de code.

[4]

Conditional GAN on MNIST (Kaggle Notebook) :
https://www.kaggle.com/code/hamiddamadi/conditional-gan-on-mnist

Carnet d'exemples sur l'application des GANs conditionnels à MNIST, pertinent pour contextes génératifs et semi-supervisés.